

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>

**Optimizacija rada ventilokonvektora podjelom na periode grijanja/hlađenja uz upotrebu
metode najmanjih kvadrata
Tehnička dokumentacija
Verzija <1.0>**

Studentski tim: Martin Vidmar

Nastavnik: Mario Vašak

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>

Sadržaj

1.	Opis podataka	3
2.	Modeli	3
3.	Obrada podataka	4
3.1	Eliminacija podataka	4
3.2	Klasretizacija	4
		5
4.	Rezultati	5
4.1	Train skup	5
4.2	Validation skup	6
5.	Zaključak	8

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>

1. Opis podataka

Podatci su bili vezani uz sjeverni i južni dio 11. kata bivše zgrade FER-a u periodu od 2018-2022. godine. Podatci su prikupljeni sa kalorimetra koji se odnosi na polukat (23 za sjever i 24 za jug). Kalorimetar je davao parametre Polazna temperatura medija, Povratna temperatura medija, Protok, Toplinska snaga predana u zone. Također su u sustavu bili zonski kontroleri koji se nalaze u svakoj sobi na polukatu. Oni nam pružaju parametre Temperatura zraka u zoni, Upravljačka naredba za element za grijanje/hlađenje.

2. Modeli

Pri predikciji podataka smo koristili model linearne regresije. Jedan je bio bez ograničenja, dok je drugi imao ograničenje $k \geq 0$. Naš model predviđa taj parametar k na temelju formule (Slika 1.1)

$$P_{E_i}(t) = k_{i,x(t)}(T_{cal,j}(t) - T_{a,i}(t))$$

$$\sum_i P_{E_i}(t) = P_{cal,j}(t) \rightarrow \text{za grupu elemenata iza kalorimetra } j$$

Slika 1.1

$T_{a,i}$ - temperatura i zoni i
 T_{cal} - temperatura kalorimetra
 P_E - snaga u sustavu

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>


3. Obrada podataka

3.1 Eliminacija podataka


Najprije je bilo potrebno očistiti podatke. Uklonjeni tu trenutci u kojima nema aktivnosti, u kojima nema podatka za pojedinu zonu(budući da nam je potrebna suma snaga svih zona kako bi dobili rezultat ukupne snage. Također smo ograničili podatke na periode od 6:00 do 17:00 budući da je izvan toga sustav neaktivan i u njemu se događaju nagle promjene u podacima.

3.2 Klasifikacija

Zatim je bilo potrebno klasterizirati podatke (protok i vrtnju ventilatora). Taj proces je prikazan na slikama 3.2.1, 3.2.2, 3.2.1.




Slika 3.2.1



Slika 3.2.2

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>



Slika 3.2.3

Ti su nam podatci potrebni jer naš model uzima u obzir ta dva faktora kako bi dobio uvid o stanju sustava i time napravio bolje predviđanje. Podatci prikazani na slikama se odnose na 2021. godinu.

4. Rezultati

4.1 Train skup

Najprije smo trenirali model i potom napravili evaluaciju na tom istom skupu. Rezultati se nalaze na slici 4.1.1. U ovom slučaju nismo imali uvjet $k \geq 0$. Stupac spojeni prikazuje spojene podatke svih navedenih godina.

	2018	2019	2020	2021	spojeni
MAE(kW)	0.24	0.16	0.14	0.2	0.2
RMSE(kW)	0.44	0.29	0.27	0.35	0.36
R2	0.93	0.942	0.961	0.946	0.944

Slika 4.1.1

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>

Zatim smo isti postupak proveli na podacima u kojima smo uzeli u obzir uvjet $k \geq 0$. Rezultati se nalaze u tablici 4.1.2.

	2018	2019	2020	2021	spojeni
MAE(kW)	0.24	0.16	0.15	0.23	0.22
RMSE(kW)	0.45	0.29	0.28	0.38	0.38
R2	0.928	0.941	0.959	0.937	0.94


Slika 4.1.2

Kao što vidimo točnost nam ne opada znatno ako dodamo uvjet, dok njime dobijemo stabilniji model.

4.2 Validation skup

Metrike za validation skup(2022. godina) su sljedeći: MAE : 0.76 kW , RMSE : 1.70 kW R^2 : 0.703. To je prihvatljiva točnost, no prikazuje da ima puno prostora za napredak. Grafički prikaz predikcije se nalazi na slikama 4.2.1 i 4.2.2.

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>



Slika 4.2.1



Slika 4.2.2

<Naziv projekta>	Verzija: <1.0>
Tehnička dokumentacija	Datum: <dd/mm/yy>

5. Zaključak

Kao što se može uvidjeti model je većinom stabilan no koče ga loše predikcije velikih raspona (horizontalne točke na slici 4.2.1. Proučavajući sustav u trenutcima najvećih pogrešaka sam došao do zaključka da model često donese odluku da je snaga u sustavu mala jer je ventilator ugašen no polazna temperatura , povratna temperatura i temperatura zone su stabilni. To ukazuje da bi povećanje složenosti modela mogli znatno poboljšati rezultate. Također bi boljim čišćenjem ulaznih podataka i povećanjem podataka da učenje bili od velike koristi.